Universidad Autónoma de Querétaro
Facultad de Ciencias Naturales
Licenciatura en Microbiología
Bioinformática
Dr. Mónica E. Figueroa Cabañas

**Práctica 9**
**Identificación bacteriana a partir del gen rRNA 16S con EzBioCloud: alcances y límites de la identificación basada en similitud**

Samuel Solís Barrón

Miércoles 30 de septiembre del 2026

## 1. Introducción

La secuenciación de genes de ARNr 16S ayuda a la identificación de la filogenia bacteriana y arqueal, pero surgen problemas cuando se aplican a nivel de especie (Chalita et al., 2024). Por tal motivo, las bases de datos de genomas filtrados para la comparación, como EzBioCloud, sirve como herramienta para la identificación taxonómica a nivel de género, especie y subespecie utilizando una combinación de búsquedas basadas en genes y cálculos OrthoANI, adoptando 98.7 % de identidad, junto con 95 % de ANI, como criterio de referencia (Chalita et al., 2024).

Las especies casi idénticas no garantiza que pertenezcan a la misma especie. Por ejemplo, *S. pneumoniae y S. pseudopneumoniae* se diferencian solo por una o dos posiciones de la región de ~ 600–900 pb (Jensen et al., 2021). Al analizar 176 genomas, Jensen et al. (2021) observaron que no se formaron agrupaciones distintivas al evaluar de manera individual los tres genes (*rpoB*, *gyrB* y *recA*).

Otro desafío son las nueve regiones hipervariables, numeradas de la V1 a la V9. Johnson et al. (2019) observaron, por ejemplo, que V1–V3 funcionó bien para identificar *Escherichia* y *Shigella*, pero no V6–V9. En la práctica evaluaremos secuencias de genomas de referencia conocida mediante EzBioCloud, considerando una similitud del 16S ≥ 98.7 % con secuencias de más de 1 300 pb.

## 2. Métodos

Los paquetes se instalaron dentro de un proyecto renv configurado para Bioconductor, de modo que las versiones exactas quedaron registradas en el archivo renv.lock y el análisis puede reproducirse en otra computadora con renv:restore(). La instalación se hizo en dos partes porque renv:init() reinicia la sesión de R.

```
# Crear el proyecto renv (se ejecuta una sola vez)

# Se instala renv (fuera de la biblioteca del proyecto)
if (!requireNamespace("renv", quietly = TRUE)) install.packages("renv")

# bioconductor = TRUE fija el proyecto a la versión de Bioconductor que
# corresponde a la versión de R instalada. La sesión de R se reinicia tr
# as esta línea.
renv::init(bioconductor = TRUE)

# Instalar y verificar los paquetes (tras el reinicio)

# Se comprueba que el proyecto renv esté activo en la sesión
if (is.null(renv::project())) {
  stop("No hay un proyecto renv activo. Use setwd() en la carpeta del pr
oyecto y reinicie R.")
}

# El prefijo "bioc::" indica a renv que descargue los paquetes de Biocon
# ductor.
# Biostrings: lectura y escritura de secuencias (Partes A, C, D y E)
# pwalign:    alineamiento pareado (Parte C)
renv::install(c("bioc::Biostrings", "bioc::pwalign"))

# Se verifica que ambos paquetes quedaron instalados; si no, se detiene
# el script con un mensaje claro (la causa más común es la falta de un c
# ompilador)
for (pkg in c("Biostrings", "pwalign")) {
  if (!requireNamespace(pkg, quietly = TRUE)) {
    stop("No se instaló ", pkg, ". Revise los mensajes de error de renv:
:install().")
  }
}

# Versiones utilizadas
library(Biostrings)
packageVersion("Biostrings")
```

```
packageVersion("pwalign")
BiocManager::version()

# Se registran las versiones exactas en renv.lock. type = "all" guarda t
# odos los paquetes de la biblioteca del proyecto; por defecto sólo se g
# uardan los que renv detecta en los scripts, y Biostrings o pwalign pod
# rían quedar fuera del archivo.
renv::snapshot(type = "all")
```

2.1. Obtención de las secuencias del gen 16S

Utilizó genomas completos de cepas de referencia conocidos, porque permite saber que organismos estamos trabajando. Respecto a las cepas E y F, son secuencias derivadas *in silico* de los casos anteriores.

La localización de los FTP de RefSeq de NCBI a partir de su número de acceso encuentra en a la tabla 1. Los archivos descargados comprenden la secuencia completa del genoma y los genes de ARN. Correspondiente a cada archivo de ARN conservó únicamente los registros que contiene al 16S ARNr, mediante el formato FASTA.

Tabla 1. Organismos de referencia utilizados en la práctica de identificación microbiana.

| *Caso* | *Organismo (cepa)* | *Ensamblado RefSeq* | *Qué se pretende mostrar* |
|---|---|---|---|
| *A* | *Pseudomonas aeruginosa* PAO1 | GCF_000006765.1 | Caso de referencia para practicar el flujo e interpretar un informe |
| *B* | *Escherichia coli* K-12 MG1655 | GCF_000005845.2 | Ambigüedad *Escherichia–Shigella*; heterogeneidad intragenómica (7 copias rrn) |
| *C* | *Bacillus anthracis* Ames | GCF_000007845.1 | Grupo *B. cereus*: especies de relevancia clínica muy distinta con 16S casi idéntico |
| *D* | *Streptococcus pneumoniae* TIGR4 | GCF_000006885.1 | Grupo *S. mitis*: patógeno frente a comensales orales |
| *E* | Derivados del caso B o C | — | Efecto de la longitud y la región (gen completo, V1–V3, V4) |
| *F* | Derivados del caso A | — | Efecto de los errores de secuenciación (0.5 %, 1 %, 2 %, 3 %) |

El siguiente código se empleó para descargar las secuencias de la tabla 1 desde NCBI:

```
# Descarga los ensamblados RefSeq de los casos A-D desde el FTP de NCBI
# a <carpeta del proyecto>/raw-data/practice-9 y extrae las copias del g
# en 16S. Los casos E y F son derivados (simulados) de B o C y de A, por
# lo que no tienen un ensamblado que descargar.
# La primera copia del 16S de cada genoma (casos A-D) se guarda en
# results/practice-9/EzBioCloud-1, lista para el envío manual a EzBioClo
# ud.
#
# Portátil: no usa rutas absolutas. La carpeta del proyecto es el proyec
# to renv (p. ej. .../bioinformatics-class), esté donde esté en cada com
# putadora. Abra esa carpeta como proyecto de R o directorio de trabajo
# antes de ejecutar.

library(Biostrings)  # lectura y escritura de secuencias (DNAStringSet,
FASTA)

# El límite por defecto (60 s) puede ser insuficiente con conexiones len
# tas
options(timeout = 600)

# Carpeta del proyecto: el proyecto renv activo; si no hay ninguno, el
# directorio de trabajo. Todas las demás rutas se construyen a partir de
# ella.
raiz <- if (requireNamespace("renv", quietly = TRUE) yy !is.null(renv::p
roject())) {
  renv::project()
} else {
  getwd()
}

# Carpeta de entrada para los genomas descargados; se crea si no existe
dir_datos <- file.path(raiz, "raw-data", "practice-9")
dir.create(dir_datos, recursive = TRUE, showWarnings = FALSE)
message("Carpeta de datos: ", normalizePath(dir_datos))

# Casos A-D: organismo, acceso del ensamblado RefSeq y nombre corto (est
# e último sólo se usa para nombrar los archivos FASTA)
genomas <- data.frame(
  caso      = c("A", "B", "C", "D"),
  organismo = c("Pseudomonas aeruginosa PAO1",
                "Escherichia coli K-12 MG1655",
                "Bacillus anthracis Ames",
                "Streptococcus pneumoniae TIGR4"),
  acc       = c("GCF_000006765.1", "GCF_000005845.2",
```

```
                "GCF_000007845.1", "GCF_000006885.1"),
  nombre    = c("Paeruginosa", "Ecoli", "Banthracis", "Spneumoniae"),
  stringsAsFactors = FALSE
)

base_ftp <- "https://ftp.ncbi.nlm.nih.gov/genomes/all"

# Construye la ruta del FTP a partir del acceso, dividiendo sus 9 dígito
# s en tres bloques: GCF_000005845.2 -> .../genomes/all/GCF/000/005/845
ruta_acc <- function(acc) {
  num    <- sub("^GCF_([0-9]+)\\.[0-9]+$", "\\1", acc) # sólo dígitos
  partes <- substring(num, c(1, 4, 7), c(3, 6, 9)) # tres bloques de 3
  paste(c(base_ftp, "GCF", partes), collapse = "/")
}

# Busca en el listado del directorio el nombre completo de la carpeta de
# l ensamblado (p. ej., GCF_000005845.2_ASM584v2)
nombre_assembly <- function(acc) {
  html <- readLines(paste0(ruta_acc(acc), "/"), warn = FALSE)
  # el punto del acceso se escapa para que no se interprete como comodín
  patron <- paste0(gsub(".", "\\.", acc, fixed = TRUE), "_[^/\"<]+")
  hits <- regmatches(html, regexpr(patron, html))
  if (length(hits) == 0) stop("No se encontró la carpeta del ensamblado
", acc)
  unique(hits)[1]
}

# Para cada caso se descargan los dos archivos de interés:
# rna_from_genomic = secuencias de rRNA, tRNA y otros RNA (contiene el 1
# 6S)
# genomic = secuencia completa del genoma
for (i in seq_len(nrow(genomas))) {
  acc <- genomas$acc[i]
  asm <- nombre_assembly(acc)
  message("Caso ", genomas$caso[i], ": ", genomas$organismo[i], " (", as
m, ")")

  for (sufijo in c("rna_from_genomic.fna.gz", "genomic.fna.gz")) {
    archivo <- paste0(asm, "_", sufijo)
    destino <- file.path(dir_datos, archivo)
    if (!file.exists(destino)) {   # no se vuelve a descargar lo que ya
existe
      download.file(paste(ruta_acc(acc), asm, archivo, sep = "/"),
                    destino, mode = "wb")
    }
  }
}
```

```
list.files(dir_datos)

# Lee un archivo FASTA de RNA de RefSeq y conserva sólo los registros de
# l 16S.
# El encabezado de cada copia contiene "product=16S ribosomal RNA".
extraer_16S <- function(archivo) {
  rna <- readDNAStringSet(archivo)
  rna[grepl("16S ribosomal RNA", names(rna))]
}

# Copias del 16S de E. coli (caso B)
ecoli <- extraer_16S(file.path(dir_datos,
                               "GCF_000005845.2_ASM584v2_rna_from_genomi
c.fna.gz"))
length(ecoli)   # número de copias del 16S en el genoma
width(ecoli)    # longitud de cada copia

# Los archivos que se someterán a EzBioCloud van en results/, no en raw-
# data, que sólo debe contener los archivos descargados
dir_salida <- file.path(raiz, "results", "practice-9", "EzBioCloud-1")
dir.create(dir_salida, recursive = TRUE, showWarnings = FALSE)

# Para cada caso (A-D): se informa el número y la longitud de las copias
# del 16S y se guarda la primera copia como un archivo FASTA independien
# te (una secuencia por archivo) para enviarla a EzBioCloud, p. ej.
# B_Ecoli_16S_copia1.fasta
for (i in seq_len(nrow(genomas))) {
  f <- list.files(dir_datos,
                  pattern = paste0("^", genomas$acc[i], ".*rna_from_geno
mic"),
                  full.names = TRUE)
  x <- extraer_16S(f)
  message("Caso ", genomas$caso[i], ": ", length(x), " copias, longitude
s ",
          paste(unique(width(x)), collapse = ", "))

  archivo <- paste0(genomas$caso[i], "_", genomas$nombre[i], "_16S_copia
1.fasta")
  writeXStringSet(x[1], file.path(dir_salida, archivo))
}
```

## 2.2. Identificación con EzBioCloud

Las copias de las secuencias descargadas se procesaron utilizando la herramienta de identificación basada en secuencias 16S rRNA de EzBioCloud. El análisis desarrolló con la identificación de las copias individualmente, subió el archivo FASTA a la plataforma en la sección 16S-based ID. Los informes generados contienen el top hit (especie y cepa tipo), su porcentaje de similitud, la completitud y la lista completa de candidatos, considerando al menos los cinco primeros hits. Sin embargo, fue necesario contar cuántas especies superaban el 98.7 % de similitud y se calculó la diferencia (Δ) entre el primer y el segundo candidato.

La similitud entre secuencia se interpretó utilizando el umbral de 98.7% propuesto para la delimitación de especie (Kim et al., 2014). Consideró que una similitud inferior a este valor sugiere que los organismos pertenecen a especies diferentes, mientras una similitud superior a este umbral, no demuestra su pertenencia a la misma especie.

## 2.3. Heterogeneidad intragenómica

Las copias del 16S del caso B (*E. coli*) y *caso C* (*B. anthracis*), compararon entre sí. Las copias alinearon con pwalign::pairwiseAlignment(), type = "global" refiere a parámetros por defecto. El porcentaje de identidad calculó con pwalign:pid(), agregó type = "PID1" para contar los huecos como factor diferenciador, esto realizado con las posiciones idénticas entre posiciones alineadas sumando las posiciones con huecos internos, multiplicado por 100. Los resultados obtenidos obtuvieron una matriz simétrica de n x n copias, cuya diagonal vale 100 porque cada copia se compara consigo misma.

Las copias más divergentes fueron sustraídas en formato FASTA, consideró las copias de secuencia con el valor que tuviera menor identidad. Después las copias compararon en la plataforma EzBioCloud para observar cambios de los parámetros obtenidos en la tabla 2. El siguiente código se empleó para la heterogeneidad intragenómica:

```
# Se comprueba que pwalign esté instalado en el proyecto renv
if (!requireNamespace("pwalign", quietly = TRUE)) {
  stop("Falta el paquete 'pwalign'. Ejecute: renv::install(\"bioc::pwali
gn\"); renv::snapshot()")
}

# Carpeta de salida de esta parte (se crea junto con results/ y practice
# -9/ si no existen)
dir_salida <- file.path(raiz, "results", "practice-9", "EzBioCloud-2")
dir.create(dir_salida, recursive = TRUE, showWarnings = FALSE)

# Localiza el archivo rna_from_genomic de un acceso (p. ej. "GCF_0000058
# 45.2") dentro de raw-data/practice-9, sea cual sea el nombre del ensam
blado
archivo_rna <- function(acc) {
  f <- list.files(dir_datos,
                  pattern = paste0("^", acc, ".*rna_from_genomic\\.fna\\
.gz$"),
                  full.names = TRUE)
  if (length(f) != 1) {
    stop("Se esperaba un archivo rna_from_genomic para ", acc, " en ", d
ir_datos,
         ". Ejecute primero la Parte A.")
  }
  f
}

# Construye una matriz de n x n con el % de identidad entre todos los pa
# res de copias.
#  - type = "global": se alinea toda la longitud de ambas secuencias.
#  - PID1: identidad = posiciones idénticas / (posiciones alineadas + po
# siciones de huecos internos) x 100; los huecos también cuentan como di
# ferencias.
#  - La diagonal vale 100 (cada copia comparada consigo misma).
# Filas y columnas se llaman c1..cn, según el orden de las secuencias.
matriz_pid <- function(secs) {
  n <- length(secs)
  etiquetas <- paste0("c", seq_len(n))
  M <- matrix(NA_real_, n, n, dimnames = list(etiquetas, etiquetas))
  for (i in seq_len(n)) for (j in seq_len(n)) {
    aln <- pwalign::pairwiseAlignment(secs[[i]], secs[[j]], type = "glob
al")
    M[i, j] <- pwalign::pid(aln, type = "PID1")
  }
```

```
  M
}

# Encuentra el par de copias con la identidad MÁS BAJA de la matriz M.
#  - La matriz es simétrica: se anulan (NA) la diagonal y el triángulo i
# nferior para ver cada par una sola vez e ignorar las autocomparaciones
#.
#  - Si varios pares empatan en el mínimo se usa el primero (índices más
bajos); n_empates indica cuántos pares comparten ese valor.
copias_mas_divergentes <- function(M) {
  if (nrow(M) < 2) stop("Se necesitan al menos dos copias para compararl
as.")
  M_sup <- M
  M_sup[lower.tri(M_sup, diag = TRUE)] <- NA
  minimo <- min(M_sup, na.rm = TRUE)
  pares <- which(M_sup == minimo, arr.ind = TRUE)
  pares <- pares[order(pares[, "row"], pares[, "col"]), , drop = FALSE]
  list(i = unname(pares[1, "row"]),
       j = unname(pares[1, "col"]),
       pid = minimo,
       n_empates = nrow(pares))
}

# Informa el par más divergente y guarda cada una de las dos copias en s
# u propio archivo FASTA (una secuencia por archivo, como requiere el en
# vío manual a EzBioCloud): <prefijo>_16S_c<k>.fasta, donde k es el núme
# ro de copia de la matriz. Se conserva el encabezado original, que iden
# tifica la copia en el genoma (locus tag).
guardar_pareja_divergente <- function(secs, M, prefijo) {
  p <- copias_mas_divergentes(M)

  message("Par más divergente: c", p$i, " vs c", p$j,
          " (", round(p$pid, 2), " % de identidad)")
  if (p$n_empates > 1) {
    message("  Nota: ", p$n_empates, " pares comparten este valor; se us
a el primero.")
  }
  if (p$pid == 100) {
    warning("Todas las copias son idénticas: el par «más divergente» es
arbitrario.")
  }
  message("  c", p$i, ": ", names(secs)[p$i], " (", width(secs)[p$i], "
pb)")
  message("  c", p$j, ": ", names(secs)[p$j], " (", width(secs)[p$j], "
pb)")

  for (k in c(p$i, p$j)) {
    archivo <- file.path(dir_salida, paste0(prefijo, "_16S_c", k, ".fast
```

```
a"))
    writeXStringSet(secs[k], archivo)
    message("  Guardado: ", archivo)
  }
  invisible(p)
}

# Copias del 16S de E. coli (se esperan 7)
ecoli <- extraer_16S(archivo_rna("GCF_000005845.2"))
length(ecoli)

# Matriz de identidad de todas contra todas (en %, redondeada para mostr
# arla)
M_ecoli <- matriz_pid(ecoli)
round(M_ecoli, 2)

# Menor identidad entre dos copias del mismo genoma, es decir, la mayor
# divergencia dentro de E. coli
min(M_ecoli)

# Se identifican las dos copias más divergentes y se guardan para EzBioC
# loud
guardar_pareja_divergente(ecoli, M_ecoli, prefijo = "B_Ecoli")

# Mismo análisis para B. anthracis
anthracis <- extraer_16S(archivo_rna("GCF_000007845.1"))
length(anthracis)   # número de copias del 16S en este genoma

M_anthracis <- matriz_pid(anthracis)
round(M_anthracis, 2)
min(M_anthracis)

guardar_pareja_divergente(anthracis, M_anthracis, prefijo = "C_Banthraci
s")
```

2.4. Efecto de la longitud y de la región variable

La generación de los cebadores 27F/534R (región V1–V3) y 515F/806R (región V4), generó mediante la primera copia del 16S del caso B. La simulación de la PCR de las regiones simuló buscando el forward tal como está escrito en el script y el iniciador reverse como el complemento de forward. Los códigos de ambigüedad IUPAC de los iniciadores (M = A/C, Y = C/T, N = cualquier base, V = A/C/G, W = A/T) se trataron como coincidencias (fixed = FALSE) y no se admitieron discrepancias adicionales (max.mismatch = 0).

Las secuencias generadas se guardaron en archivo FASTA por separado y sometieron en EzBioCloud. El registro de los datos es parecido a la tabla 1, solamente agregó si aparecía un aviso de advertencia sobre la longitud de la secuencia. El siguiente código se empleó para evaluar el efecto de la longitud y de la región variable:

```
# Genoma que se usa: "B" (E. coli K-12 MG1655) o "C" (B. anthracis Ames)
caso <- "B"

casos <- list(
  B = list(acc = "GCF_000005845.2", nombre = "Ecoli"),
  C = list(acc = "GCF_000007845.1", nombre = "Banthracis")
)
genoma <- casos[[caso]]

# Pares de iniciadores, escritos 5'->3' como se publican habitualmente.
# Las letras M, Y, N, V y W son códigos de ambigüedad IUPAC.
cebadores <- list(
  V1V3 = list(fwd = "AGAGTTTGATCMTGGCTCAG", rev = "ATTACCGCGGCTGCTGG"),
# 27F / 534R
  V4   = list(fwd = "GTGYCAGCMGCCGCGGTAA",  rev = "GGACTACNVGGGTWTCTAAT"
)  # 515F / 806R
)

# Carpeta de salida de esta parte
dir_salida <- file.path(raiz, "results", "practice-9", "EzBioCloud-3")
dir.create(dir_salida, recursive = TRUE, showWarnings = FALSE)

# Simula una PCR sobre la secuencia s y devuelve el amplicón SIN los ini
# ciadores.
#  - fwd: iniciador directo; coincide con la secuencia tal como está esc
# rito.
#  - rev: iniciador reverso; hibrida con la hebra opuesta, así que en s
```

```
# se busca su complemento reverso.
#  - fixed = FALSE permite que los códigos IUPAC de los iniciadores coin
# cidan.
#  - mm: discrepancias permitidas (0 = coincidencia exacta salvo los cód
# igos de ambigüedad). Puede aumentarse si un iniciador "no se encuentra
# " en un genoma divergente.
recortar <- function(s, fwd, rev, mm = 0) {
  f <- matchPattern(DNAString(fwd), s, max.mismatch = mm, fixed = FALSE)
  r <- matchPattern(reverseComplement(DNAString(rev)), s,
                    max.mismatch = mm, fixed = FALSE)
  if (length(f) == 0 || length(r) == 0) stop("No se encontró algún inici
ador")

# Sólo tienen sentido los sitios del iniciador reverso posteriores al pr
# imer sitio del iniciador directo
  n_sitios <- c(fwd = length(f), rev = length(r))
  r <- r[start(r) > end(f)[1]]
  if (length(r) == 0) stop("El iniciador reverso no se encontró después
del directo")
  if (any(n_sitios > 1)) {
    warning("Un iniciador se une a más de un sitio; se usa el primero vá
lido.")
  }

  message("  iniciador directo en ", start(f)[1], "-", end(f)[1],
          "; sitio del reverso en ", start(r)[1], "-", end(r)[1])
  subseq(s, start = end(f)[1] + 1, end = start(r)[1] - 1)   # sin inicia
dores
}

# Todas las copias del 16S del genoma elegido; se trabaja con la primera
copias <- extraer_16S(archivo_rna(genoma$acc))
s <- copias[[1]]
message("Se usa la copia 1 del caso ", caso, " (", names(copias)[1], ")"
)

# Un fragmento por región (V1, V3 y V4)
fragmentos <- lapply(names(cebadores), function(region) {
  message("Región ", region, ":")
  recortar(s, cebadores[[region]]$fwd, cebadores[[region]]$rev)
})
names(fragmentos) <- names(cebadores)

# Longitudes (pb) para la columna Long. (pb) de la Tabla 2
```

```
longitudes <- c(completo = length(s), sapply(fragmentos, length))
longitudes

# Una secuencia por archivo (EzBioCloud se usa de una en una):
# E_<organismo>_completo.fasta, E_<organismo>_V1V3.fasta, E_<organismo>_
# V4.fasta
# "E" = secuencias derivadas del caso B o C (caso E de la práctica)
completo <- DNAStringSet(list(completo = s))
guardar <- function(secuencia, etiqueta) {
  archivo <- file.path(dir_salida, paste0("E_", genoma$nombre, "_", etiq
ueta, ".fasta"))
  writeXStringSet(secuencia, archivo)
  message("Guardado: ", archivo)
}

guardar(completo, "completo")
for (region in names(fragmentos)) {
  guardar(DNAStringSet(setNames(list(fragmentos[[region]]), region)), re
gion)
}

# Ambos fragmentos juntos en un solo multi-FASTA (opcional, sólo de refe
# rencia: EzBioCloud requiere enviarlos por separado)
frag <- DNAStringSet(fragmentos)
writeXStringSet(frag, file.path(dir_salida, paste0("E_", genoma$nombre,
"_fragmentos.fasta")))
```

2.5. Efecto de los errores de secuenciación

La simulación de los errores de secuenciación consiguió con sustituciones al azar en la primera copia del 16S de *P. aeruginosa* PAO (caso A) con tasas de error de 0.5, 1.2 y 3%. De cada copia realizó round (longitud × tasa) con el propósito de sortear las sustituciones de las tasas de error. Adicionalmente, calculó la identidad de la mutante mediante la siguiente formula: 100 × (1 − sustituciones / longitud). El archivo FASTA generado se ingresó en EzBioCloud, realizó el mismo análisis de identificación descrito en el punto 2.2 de esta metodología.

Además, añadió un graficó de similitud frente a la tasa de error, con líneas horizontales en 98.7 % (umbral de especie) y 94.5 % (umbral de género), junto con la similitud esperada si el top hit fuera idéntico a la secuencia original (100 − tasa de error). El siguiente código se empleó para estimar el efecto de los errores de secuenciación:

```r
semilla <- 2026  # semilla aleatoria: use el número de su equipo
tasas   <- c(0.005, 0.01, 0.02, 0.03) # tasas de error: 0.5, 1, 2 y 3 %

# Similitud (%) con el top hit de EzBioCloud para cada mutante, en el mi
# smo orden que 'tasas'. Se deja NA hasta tener los resultados; luego se
# completa y se vuelve a ejecutar desde la sección de la gráfica.
sim_ezbiocloud <- c(NA, NA, NA, NA)

umbral_especie <- 98.7   # % de similitud: umbral de especie
umbral_genero  <- 94.5   # % de similitud: umbral de género

# Carpeta de salida: archivos FASTA para EzBioCloud y la gráfica
dir_res    <- file.path(raiz, "results", "practice-9")
dir_salida <- file.path(dir_res, "EzBioCloud-4")
dir.create(dir_salida, recursive = TRUE, showWarnings = FALSE)

# Introduce sustituciones al azar en la secuencia s con una tasa de erro
# r dada.
#  - x: la secuencia como vector de letras.
#  - pos: posiciones a mutar, sorteadas SIN reemplazo, de modo que cambi
# an exactamente round(longitud * tasa) posiciones distintas.
#  - Cada base elegida se sustituye por una de las otras tres (nunca por
# sí misma), así que todo sorteo es una sustitución real.
# Sólo se simulan sustituciones (sin inserciones ni deleciones).
mutar <- function(s, tasa) {
  x <- strsplit(as.character(s), "")[[1]]
  pos <- sample(length(x), round(length(x) * tasa))
  for (p in pos) x[p] <- sample(setdiff(c("A", "C", "G", "T"), x[p]), 1)
  DNAString(paste(x, collapse = ""))
}

# Número de posiciones en las que difieren dos secuencias de igual longi
# tud
n_diferencias <- function(a, b) {
  sum(strsplit(as.character(a), "")[[1]] != strsplit(as.character(b), ""
)[[1]])
}

# Con la semilla fija, las sustituciones aleatorias son reproducibles
set.seed(semilla)
```

```r
# Primera copia del 16S de P. aeruginosa PAO1 (caso A)
pae <- extraer_16S(archivo_rna("GCF_000006765.1"))[[1]]
length(pae)

# Un mutante por tasa de error, con nombres como "Pae_error_0.5pct"
mut <- DNAStringSet(lapply(tasas, function(t) mutar(pae, t)))
names(mut) <- paste0("Pae_error_", tasas * 100, "pct")

# Verificación: cuántas bases cambiaron y la identidad exacta de cada mu
# tante con la secuencia original, 100 * (1 - sustituciones / longitud).
# La similitud que reporte EzBioCloud debe ser cercana a este valor, por
# que el top hit es casi idéntico a la secuencia original.
sustituciones <- sapply(mut, function(m) n_diferencias(pae, m))
tabla <- data.frame(
  error_pct      = tasas * 100,
  sustituciones  = sustituciones,
  identidad_pct  = round(100 * (1 - sustituciones / length(pae)), 2),
  sim_ezbiocloud = sim_ezbiocloud,
  row.names      = names(mut)
)
tabla

# Una secuencia por archivo (se envían de una en una), p. ej.
# F_Pae_error_0_5pct.fasta; los puntos del nombre se sustituyen por "_"
for (k in seq_along(mut)) {
  archivo <- file.path(dir_salida,
                       paste0("F_", gsub("\\.", "_", names(mut)[k]), ".f
asta"))
  writeXStringSet(mut[k], archivo)
  message("Guardado: ", archivo)
}

# Todos los mutantes juntos (opcional, sólo de referencia)
writeXStringSet(mut, file.path(dir_salida, "F_mutantes.fasta"))

# Se actualiza la tabla con los valores de EzBioCloud que haya en
# 'sim_ezbiocloud' (edite ese vector y vuelva a ejecutar desde aquí)
tabla$sim_ezbiocloud <- sim_ezbiocloud
tabla

# Línea gris = similitud esperada si el top hit fuera idéntico a la secu
# encia original: similitud = 100 - tasa de error.
# Puntos = lo que reporta.
# EzBioCloud. Líneas horizontales discontinua y punteada = umbrales de e
# specie y de género.
dibujar <- function() {
  plot(NA, xlim = c(0, 6), ylim = c(93, 101.5),
       xlab = "Tasa de error simulada (%)",
```

```
       ylab = "Similitud con el top hit (%)",
       main = "Efecto de los errores de secuenciación sobre la identific
ación (Pae PAO1)")
  abline(a = 100, b = -1, col = "grey60")                      # similit
ud esperada
  abline(h = umbral_especie, lty = 2, col = "red",  lwd = 2)   # especie
  abline(h = umbral_genero,  lty = 3, col = "blue", lwd = 2)   # género
  text(6, umbral_especie + 0.3, "98.7 % (especie)", adj = 1, col = "red"
)
  text(6, umbral_genero  + 0.3, "94.5 % (género)",  adj = 1, col = "blue
")
  points(tabla$error_pct, tabla$identidad_pct, pch = 1, cex = 1.3, col =
"grey40")
  points(tabla$error_pct, tabla$sim_ezbiocloud, pch = 19, cex = 1.3)
  legend("topright", bty = "n",
         legend = c("Esperada (100 - error)", "Identidad exacta con el o
riginal",
                    "Top hit de EzBioCloud"),
         lty = c(1, NA, NA), pch = c(NA, 1, 19), col = c("grey60", "grey
40", "black"))
}

dibujar() # se muestra en la ventana de gráficos

png(file.path(dir_salida, "F_similitud_vs_error.png"), width = 1800, hei
ght = 1200, res = 200)
dibujar() # se guarda la misma gráfica como PNG
dev.off()

# Tasa de error a la que se cruzan los umbrales
# Con similitud = 100 - tasa de error, un aislado conocido queda por deb
# ajo de un umbral cuando la tasa de error supera 100 - umbral.
100 - umbral_especie # tasa (%) a partir de la cual parece una especie n
# ueva
100 - umbral_genero # tasa (%) a partir de la cual parece un género nuev
# o
```

## 3. Resultados

### 3.1. Identificación con EzBioCloud

En el caso A, *P. aeruginosa* y *P. paraeruginosa* obtuvimos una identidad del 100%, siendo imposible distinguirlos. Por su parte, el top hit del caso B fue un número de acceso sin nombre de especie (CP040443_s), el segundo organismo fue *E. whittamii*. En cuanto a C, *B. anthracis* obtuvo 100 %, seguida de *B. nitratireducens* con 99.93 %. Por último, en la muestra D, *S. pneumoniae* registró 99.80 % y *S. pseudopneumoniae*, 99.73 %.

Los candidatos de los casos, el primer y segundo, presentan longitudes de 1536–1552 pb. Con respecto en los casos C y D, obtuvieron 0.07 puntos porcentuales que equivale a una discrepancia de un solo nucleótido. En cuanto al caso B, no existe comparación porque carece de nombre de especie, no conviene situarlo a nivel de especie.

Tabla 2. Resultados de identificación con el gen completo.

| *Caso* | *Long. (pb)* | *Top hit (especie, cepa)* | *% sim.* | *Compl. %* | *2.º hit* | *% sim.* | *Δ (1.º–2.º)* | *N.º spp. ≥ 98.7 %* |
|---|---|---|---|---|---|---|---|---|
| *A* | 1,536 | *Pseudomonas paraeruginosa* | 100 | 97.3 | *Pseudomonas aeruginosa* | 100 | 0 | 2 |
| *B* | 1,542 | *CP040443_s* | 99.45 | 94.9 | *Escherichia whittamii* | 99.39 | 0.06 | 10 |
| *C* | 1,552 | *Bacillus anthracis* | 100 | 95.0 | *Bacillus nitratireducens* | 99.93 | 0.07 | 10 |
| *D* | 1,546 | *Streptococcus pneumoniae* | 99.80 | 95.0 | Streptococcus pseudopneumoniae | 99.73 | 0.07 | 10 |

### 3.2. Heterogeneidad intragenómica

Para el caso B, la copia c1 replica con exactitud la identidad de la fila de la tabla 1 (CP040443_s, 99,45 %; *E. whittamii*, 99,39 %; Δ = 0,06); por el contrario, la copia c3 sitúa en primer lugar a *S. sonnei* (99.66 %) y a *S. flexneri* como la segunda (99.52 %), con una diferencia de Δ = 0.14.

En la muestra del caso C, la copia c2 proporciona una identidad de 99.93% para *B. paranthracis*, empatando con *B. nitratireducens* (Δ = 0), en tanto que c4 arroja *B. anthracis* con 99.80 % frente a 99.73 % de *B. nitratireducens* (Δ = 0.07). A partir de estos datos, la fila C de la Tabla 1 no coincide con la copia c2 ni con c4, indicando probablemente que son secuencias distintas, aunque las tablas no especifican cuál.

Tabla 3. Resultados de identificación con las dos copias más divergentes.

| *Caso* | *Long. (pb)* | *Top hit (especie, cepa)* | *% sim.* | *Compl. %* | *2.º hit* | *% sim.* | *Δ (1.º−2.º)* | *N.º spp. ≥98.7 %* |
|---|---|---|---|---|---|---|---|---|
| *B_Ecoli_16S_c1* | 1,542 | *CP040443_s* | 99.45 | 94.9 | *Escherichia whittamii* | 99.39 | 0.06 | 10 |
| *B_Ecoli_16S_c3* | 1,542 | *Shigella sonnei* | 99.66 | 94.9 | *Shigella flexneri* | 99.52 | 0.14 | 10 |
| *C_Banthracis_16S_c2* | 1,552 | *Bacillus paranthracis* | 99.93 | 95.0 | *Bacillus nitratireducens* | 99.93 | 0 | 10 |
| *C_Banthracis_16S_c4* | 1,552 | *Bacillus anthracis* | 99.80 | 95.0 | *Bacillus nitratireducens* | 99.73 | 0.07 | 10 |

3.3. Efecto de la longitud y de la región variable

Tabla 4. Efecto de la longitud y de la región.

| *Secuencia* | *Long. (pb)* | *Top hit* | *% sim.* | *Compl. %* | *N.º spp. ≥98.7 %* | *¿Identificación correcta?* |
|---|---|---|---|---|---|---|
| *Gen completo* | 1,542 | *CP040443_s* | 99.45 | 94.9 | 10 | |
| *V1–V3* | 253 | *Escherichia hominis* | 100 | 100 | 10 | Low base count |
| *V4* | 490 | *Escherichia fergusonii* | 99.39 | 100 | *9* | |

3.4. Efecto de los errores de secuenciación

El análisis de secuencias con errores simulados permitió estimar hasta donde dejaría de clasificarse a nivel de especie. La Tabla 1 obtuvimos una identidad ≥ 98.7 % de los organismos analizados, del mismo modo que las tasas de error de 0.5% y 1%, esto permitió diferenciar a nivel de especie. En contraste, las tasas del 2% descendió la similitud al 97.99%, y con la tasa del 3% la similitud fue del 96.62%. Debido a que la tasa de error disminuye la similitud, el umbral para la identificación de la especie se sitúa cerca de una tasa de error del 1.3 %, equivalente a unas 20 sustituciones en una longitud de 1 536 pb.

En lo que concierne al género, la tasa de error del 3% se encuentra distante del umbral requerido para impedir la correcta asignación taxonómica a este nivel. Por tal motivo, el primer resultado sigue correspondiendo al género *Pseudomonas* las especies *P. paraeruginosa* y *P. aeruginosa*, misma que a nivel de especie no se logró diferenciar.

La gráfica de la Figura 1, el eje y muestra la similitud con el mejor resultado y el eje x, la tasa de error simulada. Los círculos abiertos indican la identidad exacta entre secuencia mutuada y las tasas de error correspondiente al tipo de porcentaje de similitud. La línea roja indica el umbral para diferenciar especie, y la línea azul corresponde al umbral de género. De modo que la intersección de la línea gris de similitud esperada y la línea roja, muestra la tasa de error de 1.3 % es el umbral para detectar especie. El umbral para detectar género ubica en la tasa de error del 5.5 %.

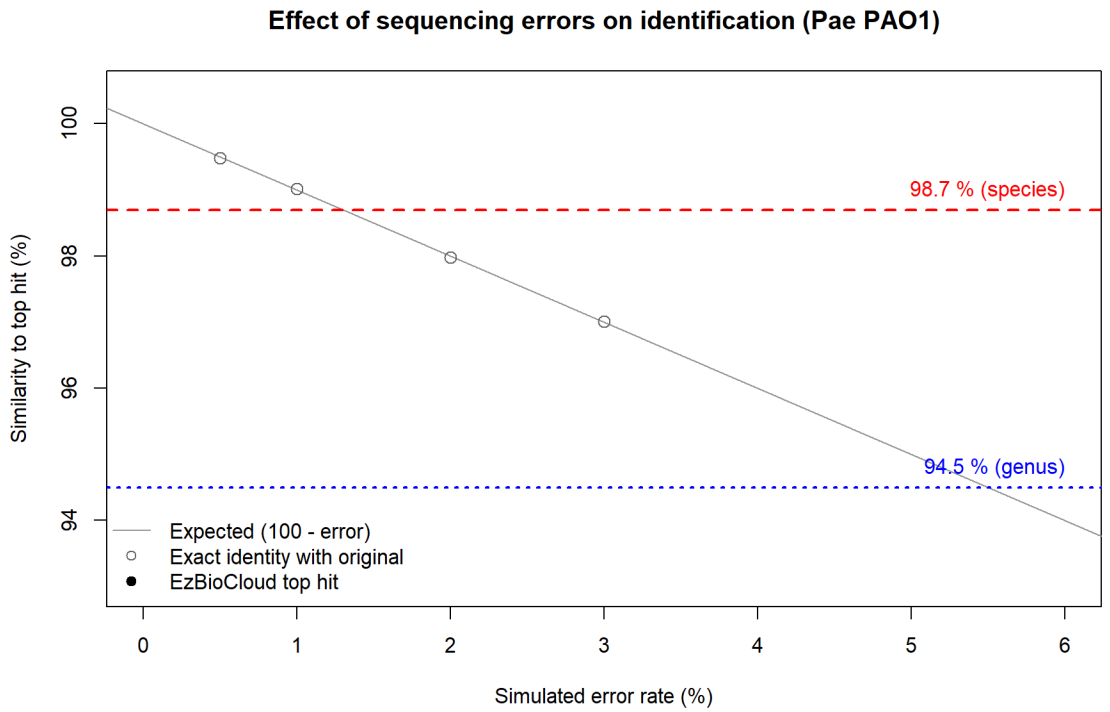



**Figura 1. Efecto de los errores de secuenciación simulados sobre la identificación de la secuencia del gen ARNr 16S de Pae PAO1 (1 536 pb) con EzBioCloud.**

Tabla 5. Efecto de los errores de secuenciación.

| *Caso* | *Long. (pb)* | *Top hit (especie, cepa)* | *% sim.* | *Compl. %* | *2.º hit* | *% sim.* | *Δ (1.º−2.º)* | *N.º spp. ≥98.7 %* |
|---|---|---|---|---|---|---|---|---|
| *Pae_error_0_5pct* | 1,536 | *Pseudomonas paraeruginosa* | 99.46 | 97.3 | *Pseudomonas aeruginosa* | 99.45 | 0.01 | 2 |
| *Pae_error_1pct* | 1,536 | *Pseudomonas paraeruginosa* | 99.06 | 97.3 | *Pseudomonas aeruginosa* | 99.04 | 0.02 | 2 |
| *Pae_error_2pct* | 1,536 | *Pseudomonas paraeruginosa* | 97.99 | 97.3 | *Pseudomonas aeruginosa* | 97.94 | 0.05 | 0 |
| *Pae_error_3pct* | 1,536 | *Pseudomonas paraeruginosa* | 96.92 | 97.3 | *Pseudomonas aeruginosa* | 96.84 | 0.08 | 0 |

## 4. Cuestionario

1. Explique la asimetría del umbral de 98.7%: ¿por qué una similitud es informativa y una mayor no necesariamente?

La similitud de 98.7% no es suficiente para asignar la especie. En el caso A la identidad alcanzó el 100% de identidad, pero los casos B al D, el primer candidato es diferente al segundo 0.6 a 0.7 puntos porcentuales, esto no explica una especie distinta. En cuanto a PAO1 de la tabla 4, desciende a 97.99% con un 2% de error simulado, junto con las demás especies ubican dentro del género de *Pseudomonas* porque el umbral es equivalente a 94.5%. La publicación de Chalita et al. (2024) advierten que las secuencias casi idénticas no garantizan congruencia de especie, esto por el locus que acumula menos sustituciones en el genoma por tener un tamaño de ~1500 pb. El resultado obtenido de *Pseudomonas* muestra una divergencia genómica como ocurre con *P. paraeruginosa* y *P. aeruginosa*, se reconocen actualmente como especies independientes, ya que los análisis filogenómicos basados en 212 genomas demostraron que constituyen dos linajes evolutivos distintos (Rudra et al., 2022).

2. En el caso B, ¿qué especies aparecen con similitud cercana a la de *E. coli*? ¿Es un problema del gen, de la base de datos o de la nomenclatura? Argumente.

Las especies que aparecen con similitud cercana *E. coli* con la copia c2 fueron CP040443_s (99.45 %) y *Escherichia whittamii* (99.39 %); la copia c3 obtuvimos *Shigella sonnei* (99.66 %) y *S. flexneri* (99.52 %) que sitúan en los dos primeros lugares, mientras que con los fragmentos aparecen *E. hominis* (100 %) y *E. fergusonii* (99.39 %).

Por lo anterior, las diferencias observadas entre los mejores candidatos son 0.06 a 0.14 puntos porcentuales de similitud. Al ser taxones cercanos como sucede con *E. coli* y *Shigella*, la evidencia indica que los identificadores como 16S rRNA y *rpoB*, no ayudan a la identificación taxonómica (Halimeh et al., 2021). Además, las metodologías genómicas como ANI, no logran separar en algunos casos de manera consistente a *Shigella* y *E. coli,*

probablemente debido a la proximidad filogenética por la divergencia evolutiva (Halimeh et al., 2021).

La plataforma EzBioCloud establecen estrategias de clasificación fundamentadas en genomas completos, ANI y genes conservados. Por lo que respecta, Chalita et al. (2024) sugieren que EzBioCloud incorpora especies con nomenclatura válida en conjunto con especies candidatas mediante la similitud del gen 16S ARNr, ANI y agrupamiento derivados de cgANI. Por esta razón, vemos identificadores como CP040443_s o de otros nombres provisionales dentro de los resultados

3. En el caso C, suponga que el aislado proviene de una muestra clínica. ¿Qué consecuencias tendrán informar *Bacillus cereus* o *Bacillus anthracis* basándose en el 16S? ¿Qué pruebas adicionales solicitaría?

La tabla 1 observamos *B. anthracis* obtiene el 100% de similitud seguido de *B. nitratireducens* con 99.93%. La tabla 2 sugieren que la asignación depende de la copia analizada. La similitud observada en la copia c2 fue del 99.93%, diferente a la copia c4 que representa una similitud del 99.80%. Por consecuencia, Carroll et al. (2020) señalan la importancia de la distinción porque *B. anthracis* representa un mayor riesgo biológico por las toxinas que son codificadas por los plásmidos pXO1 y pXO2, a diferencia de *B. cereus* causante de intoxicaciones alimentarias por las enterotoxinas.

Por tal motivo, los taxones estrechamente relacionados deberán completarse mediante PCR-RFLP a los marcadores de los plásmidos pXO1, pXO2 y secuencia cromosómica Ba813, esto permite distinguir cepas de *B. anthracis* con y sin plásmidos de otros *Bacillus*, incluidos los que portan Ba183. Otra alternativa, es la secuenciación basada en ANI o del genoma completo. Pero deberá incluir pruebas fenotípicas clásicas como hemólisis, motilidad y susceptibilidad a penicilina (Kędrak-Jabłońska y Budniak, 2025).

4. En el caso D, ¿por qué es clínicamente relevante distinguir *S. pneumoniae* de *S. mitis* y *S. pseudopneumoniae*? ¿Qué marcadores o pruebas se emplean en la práctica?

La similitud en *S. pneumoniae* presentó 99.80% y *S. pseudopneumoniae* el 99.73%. Está ligera variación evidencia la limitada capacidad discriminatoria del gen 16S ARNr para identificar especie. Dado que, *S. pneumoniae* provoca neumonía, meningitis y bacteriemia, el cual varía respecto de *S. pseudopneumoniae*, encontrado en el microbiota oral (Imai et al., 2020).

Las pruebas fenotípicas empleadas no bastan, como señalan Jensen et al. (2021), la susceptibilidad a la optoquina y la solubilidad en bilis se observan resultados contradictorios entre cepas. Además, los marcadores genéticos no resuelven el problema, porque ningún gen identificó por sí solo todas las cepas de *S. pseudopneumoniae*. Imai et al. (2020) mencionan que el análisis de secuencias multilocus con siete genes es el método más fiable. Alternativamente, la identificación de *S. pneumoniae* mediante el marcador genético SPN0001 funciona como marcador conservado dentro de la especie. Esto permite que la PCR en tiempo real discrimine *S. pneumoniae* de otros estreptococos.

5. Con base en la Parte C, ¿qué ocurre con el electroferograma de Sanger cuando las copias del 16S de un genoma difieren entre sí?

Los resultados de las copias del gen 16S ARNr sugieren diferencias en determinadas posiciones nucleotídicas, pero no puede cuantificarse sin una matriz de similitud o alineamiento directo. En el caso de *E. coli*, las copias divergentes producen asignaciones distintas, donde el clúster C1 presentó una coincidencia con CP040443_s (99.45 %) y el C3 con *Shigella sonnei*. (99.66 %), con valores Δ de 0.06 y 0.14. De forma análoga, en *Bacillus anthracis*, las copias c2 y c4 generan coincidencias con *Bacillus paranthracis* ($\Delta = 0$) y *Bacillus anthracis* ($\Delta = 0.07$).

La amplificación simultánea de varias copias no idénticas podría generar señales superpuestas en secuenciación Sanger, en específico sitios polimórficos compartidos por distintas variantes del gen. También el desfase ocasionado por las inserciones o deleciones entre copias, provocan pérdida progresiva de calidad de lectura. En este sentido, da Silva et

al. (2019) describieron dos tipos de electroferogramas para amplicones del gen 16S rRNA: único pico por posición o múltiples picos. Obteniendo un patrón mixto, combinado con el análisis de restricción, indicó heterogeneidad intragenómica en el 49 % de los endófitos analizados.

La secuenciación de longitud completa del gen 16S ARNr resuelve sustituciones entre copias intragenómicas, aunque las inserciones y deleciones continúan siendo más difíciles de interpretar (Johnson et al., 2019). Esto sugiere que los indels podrían generar desfases entre secuencias superpuestas.

El ruido observado en los casos B y C en los electroferogramas sería suficiente para inferir heterogeneidad intragenómica sin recurrir a clonación previa o a secuenciación de moléculas individuales.

6. ¿Qué región variable resultó más informativa en la Parte D? ¿Qué implica esto para la asignación de especie en estudios de microbioma basados en V4?

Las regiones V1-V3 genero *E. hominis* tuviera 100% de identidad, completitud del 100%, diez especies con ≥ 98.7 % de similitud y la advertencia “Low base count”, mientras que la región V4 produjo *E. fergusonii* obtuviera 99.39 % de identidad y nueve especies candidatas. Para este caso, la región V1-V3 resultó más informativa al reducir el número de especies compatibles. No obstante, ambas regiones no permitieron identificar a *E. coli*. Johnson et al. (2019) demostraron la secuenciación de regiones variables de lecturas cortas no alcanzan la resolución taxonómica del gen 16S completo. En cambio, la interpretación solamente con la región V4 es insuficiente para discriminar especies estrechamente relacionadas, necesitando complementarse con regiones adicionales o la secuencia del gen completo.

La clasificación depende de la región amplificada, porque Winand et al. (2020) observaron que el consenso entre varias regiones eliminaba la mayoría de los falsos

positivos, pero no a nivel de especie. Por lo tanto, la región V4 resulta prudente informar la asignación como grupo *Escherichia-Shigella*, o limitarse a nivel de género.

7. Proponga un criterio mínimo de calidad (longitud, bases ambiguas, calidad Phred) para aceptar una secuencia antes de identificarla, basándose en la Parte E.

Los resultados mostraron una resolución taxonómica a medida que incrementa el porcentaje de error. El error mínimo del 0.5% causa una identidad del 99.46%, pero la capacidad discriminatoria del valor Δ desciende a 0.01, lo que introduce una ambigüedad significativa en la distinción entre *P. paraeruginosa* y *P. aeruginosa*. La tasa de error al 2% no podemos diferenciar a nivel de especie, solo a nivel de género. A nivel de género el umbral máximo de tolerancia es una tasa de error al 5.5%.

La propuesta para interpretación de secuencias 16S es tener secuencias ≥ 1300 pb para asignaciones de especie y ≥ 500 pb para asignaciones de género; ≤ 0.2 % de bases ambiguas; errores y ambigüedades combinados ≤ 0.5 %; y una calidad media ≥ Q30 tras el recorte de extremos, con consenso entre lecturas directa e inversa. Por ejemplo, Locher et al. (2022) emplearon criterios de calidad superior a Q30 junto con fragmentos de 500 pb del gen 16S permite una identificación a nivel de género, pero con limitaciones a nivel de especies. Sin embargo, el clasificador de genomas EzBioCloud requiere la longitud del 16S extraído supere los 1 300 pb (Chalita et al., 2024).

8. ¿Por qué EzBioCloud compara sólo contra cepas tipo y no contra todas las secuencias depositadas en GenBank? ¿Qué ventajas y riesgos tiene hacerlo con BLAST en NCBI contra la colección nr/nt?

En lo que respecta, EzBioCloud incorpora especies candidatas que proporciona un marco de nomenclatura estable, pero no garantiza estar libre de error en la asignación taxonómica. Ahora bien, la solidez de EzBioCloud radica en la curación de las secuencias y asignaciones taxonómicas, a partir de secuencias de cepas tipo desde IJSEM y NCBI, verificadas con la literatura, alineamiento manual basado en la estructura secundaria del 16S ARNr y la validación mediante análisis genómicos (Chalita et al., 2024).

Las ventajas de nr/nt resultarían en la incorporación de secuencias procedentes de organismos no cultivados y taxones que carecen de cepa tipo representativa. Por el contrario, la mayor heterogeneidad podría aumentar los problemas asociados a anotaciones inconsistentes, vacíos en los conjuntos de referencia y ambigüedades taxonómicas. Por tal motivo, Church et al. (2020) mencionan que la identificación basada en 16S está sujeto a la calidad y cobertura de las bases de referencia.

9. Redacte cómo informaría el resultado de un aislado cuyo 16S supera 98.7 % con tres especies distintas (p. ej., «perteneciente al grupo…», «más cercano a…»).

Las que presentan el mismo número de coincidencias, no es posible una llamada de especie, deberá subirse de nivel taxonómico (Church et al., 2020). En el caso C, la identificación de *Bacillus anthracis* encontró diez especies con una similitud ≥ 98.7 %. Dado lo anterior, la descripción agrupará las secuencias a nivel de género.

Si las coincidencias pertenecen a géneros distintos, como *E. coli* y *Shigella*, no obstante, previamente observó coincidencia de similitud. La descripción agrupará las secuencias a nivel de familia.

Por su parte, las discrepancias observadas en regiones variables, describirá la agrupación como “cercano a”. Esto mismo se observa con las secuencias de *B. anthracis*, *B. cereus*, *B. wiedmannii* y *B. thuringiensis*, cuyas secuencias son casi idénticas.

10. Diseñe un esquema de identificación escalonado (16S → genes adicionales como *gyrB*, *rpoB* o *tuf* → genoma completo/ANI) e indique en qué situaciones se justifica cada nivel.

Paso 1: Control de calidad de las secuencias descargadas con el gen 16S. Utilizar para identificar errores en la secuenciación o la amplificación por PCR, y asegurar que cumplan las secuencias con los estándares de calidad para realizar las comparaciones de similitud. La plataforma de visualización y manipulación sugiere para utilizar es BioEdit.

Paso 2: Analizar las secuencias en EzBioCloud. La base de datos tiene como función la identificación taxonómica. La herramienta es adecuada, en la medida en que exista un único candidato ≥ 98.7 %, debe tener una diferencia (Δ) clara respecto al siguiente candidato.

Paso 3: Analizar las tasas de error de las secuencias. Este procedimiento, evalúa el porcentaje de error en las secuencias, lo que permite definir los umbrales de identificación a nivel de especie o género.

Paso 4: Control de calidad de las secuencias descargadas con el gen *gyrB*, *rpoB* o *tuf*. Repetir el procedimiento del paso 1, pero con otro marcador genético. La decisión de utilizar una región conservada alternativa al 16 S, surge como consecuencia a los resultados del paso 2. Al obtener más de un candidato con similitud ≥ 98.7 % o diferencia casi nula entre especies, deberá escoger otro marcador para diferenciar, basándose en genes funcionales o estructurales que aportan variabilidad genética.

Paso 5: Repetir el paso 3 y 4.

Paso 6: Analizar con ANI. La identidad promedio de nucleótidos utiliza para comparar miles de pares de bases de las regiones homólogas entre dos genomas bacterianos. Chalita et al. (2024) mencionan el cgANI es complemento, no sustituye a los umbrales de género y especie. Además, Riesco y Trujillo (2024) recomiendan estándares mínimos para la taxonomía procariota: <1,000 contigs, N50 >5 kb, completitud > 50 % y contaminación < 10 %.

## 5. Conclusión

La asignación taxonómica mediante el gen 16S, utilizó secuencias conocidas de alta calidad, para prevenir conflictos en el análisis bioinformático. Esta estrategia de asignación nos permitió abordar el análisis en ausencia de una única especie de referencia. En la práctica, varias especies superaron el umbral de 98.7% con un margen mínimo (Δ) respecto del segundo candidato. Al fallar lo anterior, únicamente se reporta a nivel de género o asignación más cercana.

Las sustituciones introducidas en el gen de PAO1, con longitud de 1 536 pb, redujeron la similitud por debajo de 98.7 %, con una tasa de error de aproximadamente 1.3 % (unas 20 posiciones). Por ende, la tasa de error del 2% imposibilitó la asignación a nivel de especie, conservándose la resolución a nivel de género. No obstante, la magnitud del error no es indicativo de la asignación, ya que constituye un supuesto teórico, no la observación real del organismo. El objetivo es determinar el rango de variación para identificar la especie.

En otros casos, las copias de un mismo genoma presentaron un 100 % de similitud entre dos especies. A causa de la microheterogeneidad intragenómica de las copias, dado que acumula muy pocas sustituciones informativas en linajes de divergencia reciente, como *Escherichia–Shigella*. Pero no demuestra la pertenencia a la misma especie, por lo tanto, se recomienda utilizar otro gen marcador para diferenciar a nivel de especie.

A raíz de esto, en los casos en que la similitud del gen 16S resultan ambiguos o muy cercanos entre varias especies, la asignación debe informarse a nivel de género o de grupo. Posteriormente, la asignación deberá resolverse mediante genes de mantenimiento, utilizados como marcadores secundarios, en combinación con la identidad media de nucleótidos (ANI).

## 6. Referencias


1. Carroll, L. M., Wiedmann, M., y Kovac, J. (2020). Proposal of a taxonomic nomenclature for the *Bacillus cereus* group which reconciles genomic definitions of bacterial species with clinical and industrial phenotypes. *mBio*, *11*(1), Article e00034-20. https://doi.org/10.1128/mBio.00034-20
2. Chalita, M., Kim, Y. O., Park, S., Oh, H.-S., Cho, J. H., Moon, J., Baek, N., Moon, C., Lee, K., Yang, J., Nam, G. G., Jung, Y., Na, S.-I., Bailey, M. J., y Chun, J. (2024). EzBioCloud: A genome-driven database and platform for microbiome identification and discovery. *International Journal of Systematic and Evolutionary Microbiology*, *74*(6), Article 006421. https://doi.org/10.1099/ijsem.0.006421
3. Church, D. L., Cerutti, L., Gürtler, A., Griener, T., Zelazny, A., y Emler, S. (2020). Performance and application of 16S rRNA gene cycle sequencing for routine identification of bacteria in the clinical microbiology laboratory. *Clinical Microbiology Reviews*, *33*(4), Article e00053-19. https://doi.org/10.1128/CMR.00053-19
4. da Silva, C. B., dos Santos, H. R. M., Marbach, P. A. S., de Souza, J. T., Cruz-Magalhães, V., Argôlo-Filho, R. C., y Loguercio, L. L. (2019). First-tier detection of intragenomic 16S rRNA gene variation in culturable endophytic bacteria from cacao seeds. *PeerJ*, *7*, Article e7452. https://doi.org/10.7717/peerj.7452
5. Halimeh, F. B., Rafei, R., Osman, M., Kassem, I. I., Diene, S. M., Dabboussi, F., Rolain, J.-M., y Hamze, M. (2021). Historical, current, and emerging tools for identification and serotyping of *Shigella*. *Brazilian Journal of Microbiology*, *52*(4), 2043–2055. https://doi.org/10.1007/s42770-021-00573-5
6. Imai, K., Nemoto, R., Kodana, M., Tarumoto, N., Sakai, J., Kawamura, T., Ikebuchi, K., Mitsutake, K., Murakami, T., Maesaki, S., Fujiwara, T., Hayakawa, S., Hoshino, T., Seki, M., y Maeda, T. (2020). Rapid and accurate species identification of mitis group streptococci using the MinION Nanopore Sequencer. *Frontiers in Cellular and Infection Microbiology*, *10*, Article 11. https://doi.org/10.3389/fcimb.2020.00011
7. Jensen, C. S., Iversen, K. H., Dargis, R., Shewmaker, P., Rasmussen, S., Christensen, J. J., y Nielsen, X. C. (2021). *Streptococcus pseudopneumoniae*: Use of whole-

genome sequences to validate species identification methods. *Journal of Clinical Microbiology*, *59*(2), Article e02503-20. https://doi.org/10.1128/JCM.02503-20

8. Johnson, J. S., Spakowicz, D. J., Hong, B.-Y., Petersen, L. M., Demkowicz, P., Chen, L., Leopold, S. R., Hanson, B. M., Agresta, H. O., Gerstein, M., Sodergren, E., y Weinstock, G. M. (2019). Evaluation of 16S rRNA gene sequencing for species and strain-level microbiome analysis. *Nature Communications*, *10*, Article 5029. https://doi.org/10.1038/s41467-019-13036-1
9. Kędrak-Jabłońska, A., y Budniak, S. (2025). The application of multiplex PCR and PCR-restriction fragment length polymorphism for differentiation of *Bacillus anthracis* from other *Bacillus* spp. *Journal of Veterinary Research*, *69*(3), 325–330. https://doi.org/10.2478/jvetres-2025-0053
10. Kim, M., Oh, H.-S., Park, S.-C., y Chun, J. (2014). Towards a taxonomic coherence between average nucleotide identity and 16S rRNA gene sequence similarity for species demarcation of prokaryotes. *International Journal of Systematic and Evolutionary Microbiology*, *64*(2), 346–351. https://doi.org/10.1099/ijs.0.059774-0
11. Locher, K., Belanger, C. R., Eckbo, E., Caza, M., Velapatino, B., y Charles, M. K. (2022). Automated 16S sequencing using an R-based analysis module for bacterial identification. *Microbiology Spectrum*, *10*(2), Article e00408-22. https://doi.org/10.1128/spectrum.00408-22
12. Riesco, R., y Trujillo, M. E. (2024). Update on the proposed minimal standards for the use of genome data for the taxonomy of prokaryotes. *International Journal of Systematic and Evolutionary Microbiology*, *74*(3), Article 006300. https://doi.org/10.1099/ijsem.0.006300
13. Rudra, B., Duncan, L., Shah, A. J., Shah, H. N., y Gupta, R. S. (2022). Phylogenomic and comparative genomic studies robustly demarcate two distinct clades of *Pseudomonas aeruginosa* strains: Proposal to transfer the strains from an outlier clade to a novel species *Pseudomonas paraeruginosa* sp. nov. *International Journal*

*of Systematic and Evolutionary Microbiology*, *72*(11), Article 005542. https://doi.org/10.1099/ijsem.0.005542

14. Winand, R., Bogaerts, B., Hoffman, S., Lefevre, L., Delvoye, M., Van Braekel, J., Fu, Q., Roosens, N. H. C., De Keersmaecker, S. C. J., y Vanneste, K. (2020). Targeting the 16S rRNA gene for bacterial identification in complex mixed samples: Comparative evaluation of second (Illumina) and third (Oxford Nanopore Technologies) generation sequencing technologies. *International Journal of Molecular Sciences*, *21*(1), Article 298. https://doi.org/10.3390/ijms21010298
15. Yarza, P., Yilmaz, P., Pruesse, E., Glöckner, F. O., Ludwig, W., Schleifer, K.-H., Whitman, W. B., Euzéby, J., Amann, R., y Rosselló-Móra, R. (2014). Uniting the classification of cultured and uncultured bacteria and archaea using 16S rRNA gene sequences. *Nature Reviews Microbiology*, *12*(9), 635–645. https://doi.org/10.1038/nrmicro3330
16. Yoon, S.-H., Ha, S.-M., Kwon, S., Lim, J., Kim, Y., Seo, H., y Chun, J. (2017). Introducing EzBioCloud: A taxonomically united database of 16S rRNA gene sequences and whole-genome assemblies. *International Journal of Systematic and Evolutionary Microbiology*, *67*(5), 1613–1617. https://doi.org/10.1099/ijsem.0.001755